I-ITWK Hochschule für Technik, Wirtschaft und Kultur Lei



Resilienz und Fehlertoleranz in verteilten Systemen

Modul "Software Engineering"

14. Januar 2025 Derhachov, Schmidt, Westholt

HTWK Leipzig, FIM

Gliederung

- 1 Resilienz und Fehlertoleranz
- 2 Strategien
- 3 Pattern und Konzepte
- 4 Fazit
- 5 Diskussion
- 6 Quellen
- 7 Cheatsheet zum Lernen



Initiales Beispiel 1.

Architekturdiagramm für Videostreaming-Platform

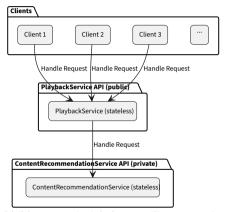


Abbildung 1: Beispiel ohne Resilienzstrategien



Begriffsklärung

Begriffe

- Resilienz
 - ► Funktionsfähigkeit trotz Störungen, Angriffen oder Ausfällen sowie schnelle Erholung
- Fehlertoleranz
 - ► Korrektes Funktionieren trotz Fehlern oder Störungen



Begriffsklärung - Zusammenhang

Zusammenhang

- **Resilienz** = übergeordnetes Konzept, umfasst Fehlertoleranz sowie Aspekte wie Wiederherstellung, Anpassungsfähigkeit und präventive Maßnahmen
- **Fehlertoleranz** = Fokus auf unmittelbarer Bewältigung von Fehlern während des Systembetriebs



Begriffsklärung - Ursprung

- beide Begriffe haben ihren Ursprung nicht in der Informatik
- Resilienz aus dem Lateinischen resilire, entspricht "zurückspringen"oder "abprallen"
- Fehlertoleranz aus den Ingenieurwissenschaften



Motivation

Motivation

- Störungen im laufenden Betrieb sollen verhindert werden
- Zugunsten der Sicherheit, Kundenzufriedenheit etc.



Initiales Beispiel 2.

- wie können wir Resilienz und Fehlertoleranz am Beispiel weiterführen?
- Zunächst natürlich grob, weil die Strategien und Pattern ja noch kommen.



StrategienResilienzstrategien

- Redundanz
- Partitionierung
- Skalierung



Resilienzstrategien: Redundanz

Definition Redundanz

Vervielfältigung kritischer Komponenten oder Funktionen zur Erhöhung der Zuverlässigkeit und Verfügbarkeit.

• Unterschiede in Arten der Redundanz und Ebenen der Redundanz.



Resilienzstrategien: Arten der Redundanz

- Aktive Redundanz
 - ► Mehrere Komponenten arbeiten parallel
 - ► Nahtloser Übergang bei Ausfall einer Komponente
- Passive Redundanz
 - ► Redundante Komponenten im Standby.
 - Aktivierung bei Ausfall der primären Komponente (mit Umschaltzeit)



Resilienzstrategien: Ebenen der Redundanz

- Software-Redundanz
 - ► Mehrere Softwarekomponenten erfüllen dieselbe Funktion
- Hardware-Redundanz
 - ▶ Doppelte physische Komponenten (z. B. Netzteile, RAID-Systeme)
- Daten-Redundanz
 - ► Mehrfach gespeicherte Daten (z. B. Replikation, Backups)
- Netzwerk-Redundanz
 - ► Alternative Übertragungswege (z. B. redundante Router, Glasfaserverbindungen)
- Geografische Redundanz
 - ► Verteilung auf mehrere Standorte zur Minimierung großflächiger Ausfälle



Resilienzstrategien: Partionierung

Definition Partionierung

Physische Unterteilung von Daten in kleinere, logisch zusammenhängende Einheiten für Skalierbarkeit, Leistung und Flexibilität.



Resilienzstrategien: Arten der Partionierung

- Horizontale Partitionierung: Aufteilung von Datensätzen basierend auf einem Partitionsschlüssel
- Vertikale Partitionierung: Gruppierung von Spalten einer Tabelle
- Funktionale Partitionierung: Organisation nach Funktion oder Zweck der Daten
- RANGE-Partitionierung: Unterteilung nach Wertebereichen (z. B. Zeit, Zahlen)
- HASH-Partitionierung: Verteilung durch Hash-Funktion für gleichmäßige Last
- Round-Robin Partitioning: Gleichmäßige, zyklische Datenverteilung



Resilienzstrategien: Skalierung

Definition Skalierung

Flexible Anpassung von Ressourcen an veränderte Anforderungen.



Resilienzstrategien: Arten der Skalierung

- Vertikale Skalierung (Scale Up)
 - ► Aufrüstung von Hardware (z. B. CPU, RAM) eines Systems
 - Begrenzung auf eine zentrale Einheit
- Horizontale Skalierung (Scale Out):
 - ► Hinzufügen von Servern oder Instanzen
 - ► Verteilte Last auf mehrere Einheiten
- Automatische Skalierung:
 - Dynamische Anpassung der Ressourcen
 - ► Häufig in Cloud-Umgebungen für optimierte Ressourcennutzung



Strategien Pattern für Fehlertoleranzstrategien

- Fehlerbehandlung und -isolierung mittels Retry-Pattern
- Nutzung von Fallback-Mechanismen
- Vermeidung kaskadierender Fehler mittels Circuit-Breaker



Pattern und Konzepte Circuit-Breaker

Definition - Was ist ein Circuit-Breaker?

Entwurfsmuster zur Isolation fehlerhafter Dienste in verteilten Systemen, um Überlastung zu verhindern und Stabilität zu gewährleisten.

Aufgaben

- Isoliert fehlerhafte Dienste
- Unterbricht Anfragen bei wiederholtem Fehler
- Verhindert kaskadierende Ausfälle



Circuit-Breaker: Zustandsdiagramm

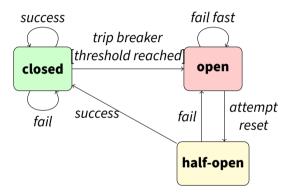


Abbildung 2: Circuit Breaker Zustandsdiagramm



Circuit-Breaker: Implementierungsansätze

- Clientseitig
 - ► Abfangen externer Anfragen vor der Weiterleitung
- Dienstseitig
 - Schutz des Dienstes vor Überlastung durch viele fehlerhafte Anfragen
- Proxy-basiert
 - ► Circuit-Breaker zwischen Clients und Diensten in Proxys platziert



Circuit-Breaker: Vorteile

- Verhindert kaskadierende Ausfälle in verteilten Systemen
- Verbesserte Systemstabilität durch Isolierung fehlerhafter Dienste
- Bessere Benutzererfahrung durch Fallback-Mechanismen
- Unterstützt Resilienz und Wiederherstellung in kritischen Systemen



Circuit-Breaker: Nachteile

- Erhöhte Komplexität in der Implementierung und Wartung
- Risiko von Fehlkonfiguration (z. B. falsche Schwellenwerte)
- Zusätzlicher Overhead durch Überwachung und Statusverwaltung
- Fallback-Daten können veraltet oder ungenau sein



Circuit-Breaker: großes Diagramm mit Anpassungen

Architekturdiagramm für Videostreaming-Platform

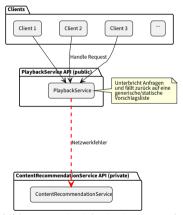


Abbildung 3: Beispiel mit Circuit Breaker



Pattern und Konzepte Retry-Muster

Definition - Was ist ein Retry-Muster?

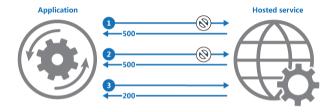
Architekturmuster zur automatischen Wiederholung fehlgeschlagener Operationen, insbesondere bei vorübergehenden Fehlern.

Funktionen

- Handhabt vorübergehende Fehler durch wiederholte Versuche
- Nutzt dazu exponentielle Backoff-Strategien (= Verlängerung der Wartezeit zwischen Wiederholungen)



Retry-Muster: Sequenzdiagramm



- 1: Application invokes operation on hosted service. The request fails, and the service host responds with HTTP response code 500 (internal server error).
- 2: Application waits for a short interval and tries again. The request still fails with HTTP response code 500.
- 3: Application waits for a longer interval and tries again. The request succeeds with HTTP response code 200 (OK).

Abbildung 4: Sequenzdiagramm des Retry Patterns [3]



Retry-Muster: Vorteile

- Reduziert die Wahrscheinlichkeit eines vollständigen Anwendungsabsturzes bei vorübergehenden Fehlern.
- Verbessert die Zuverlässigkeit, indem kurzfristige Probleme (z. B. Netzwerkprobleme) automatisch überwunden werden.
- Ermöglicht ein einheitliches Fehlerbehandlungsmodell in einer Anwendung.



Retry-Muster: Nachteile

- Erhöhte Komplexität in der Implementierung und Wartung.
- Verzögert die Gesamtverarbeitung, wenn ein Vorgang wiederholt fehlschlägt.
- Kann echte, dauerhafte Fehler verschleiern, wenn nur wiederholt wird, ohne die Ursache zu analysieren.
- Nicht jeder Fehler ist vorübergehend (z. B. Authentifizierungsfehler), was zu unnötigen Wiederholungen führt.



Pattern und Konzepte Kombination mit Circuit-Breaker

- Stoppt Wiederholungen bei permanenten Fehlern
- Ermöglicht Systemen, sich zu erholen
- Optimiert Ressourcennutzung



Pattern und Konzepte Load Balancing

Definition - Was ist Load-Balancing?

Verteilung der Last auf mehrere Server zur Verbesserung von Leistung und Ausfallsicherheit

Arten

- Network Load Balancer
- Application Load Balancer
- Hardware Load Balancer



Load Balancing: Service Discovery

Service Discovery

- Server-side Discovery
 - ► Ein zentraler Load Balancer
 - ► Dienste sind unsichtbar für Client
- Client-side Discovery
 - ► Kein zentraler Load Balancer
 - Client sieht alle Dienstinstanzen
 - Client betreibt Load Balancing



Load Balancing: Architekturdiagramm

Komponenten

- Load Balancer
- Service Registry
- Dienstinstanzen

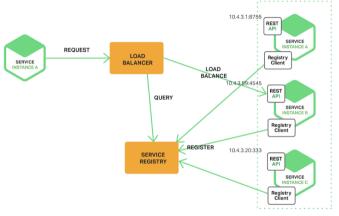


Abbildung 5: Load Balancer mit Server Side Discovery [4]



Load Balancing: statische Strategien

Source IP Hash Load Balancing

- Clients werden praktisch zufällig verteilt
- Anfragen eines Clients werden immer auf der selben Serviceinstanz verarbeitet (Sticky Sessions)

Round Robin

• Anfragen werden zyklisch auf Instanzen verteilt



Load Balancing: dynamische Strategien

Least Connection

 Anstehende Aufgabe geht an den Dienst mit den momentan wenigsten aktiven Netzwerkverbindungen

Resource Based

- Serviceknoten berichten aktuelle Auslastung (z.B. CPU-Auslastung)
- Nächste Aufgabe geht an den Knoten mit niedrigster Auslastung



Load Balancing: dynamische Strategien

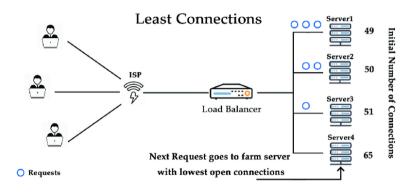


Abbildung 6: Least Connection-basiertes Load Balancing [1]



Health Checks bei Load Balancing

Konzept

Dienstinstanzen kommunizieren ihren Grad der Funktionsbereitschaft, um dynamische Lastverteilung zu ermöglichen.

- Dienste haben Endpunkte, um Auslastung oder Fehler abzurufen
- Überlastete Dienste erhalten weniger Anfragen
- Fehlerhafte Dienste können übergangen werden



Load Balancing: dynamische Skalierung

Problem

- Die Anzahl der Anfragen ist nicht immer gleich
 - Zur Spitzenbelastung sind mehr Dienstknoten nötig
 - ▶ In Ruhezeiten verschwenden unterbelastete Knoten Strom und Geld

Die Lösung: dynamische Skalierung

- Der Load Balancer wird befähigt, Dienstinstanzen zu starten und stoppen
- Schwellwerte definieren, wann dies erfolgen soll



Load Balancing: Vorteile

- Gesteigerter Durchsatz durch parallel laufende Dienste
- Hohe Verfügbarkeit durch Redundanz und nahtlosem Failover
- Kostenreduktion durch dynamische horizontale Skalierung



Load Balancing: Nachteile

- Deutlich gesteigerte Komplexität der Infrastruktur
- Zusätzliche Kosten für Load Balancer (Hardware und Lizenz)
- Dienste sind nicht immer kompatibel
 - ► Healthchecks müssen implementiert werden
 - Stateful-Dienste sind nur eingeschränkt verwendbar
- Anstelle eines einzelnen Dienstes ist jetzt der Load Balancer ein Single Point of Failure



Round Robin DNS

Definition - was ist Round Robin DNS?

- Für eine Domain werden mehrere IP-Adressen hinterlegt
- DNS-Server gibt alle Adressen in rotierender Reihenfolge zurück

Wirkung

- Externes, statisches Load Balancing
- Verfügbarkeit auch bei Totalausfall eines Servers



Round Robin DNS

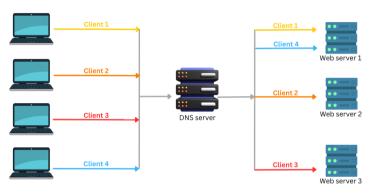


Abbildung 7: Round Robin DNS [2]



Round Robin DNS: Vorteile

- Einfach zu implementieren
- Sticky Sessions by default
- Fallback auf eine andere IP-Adresse schützt auch bei einem Serverausfall



Round Robin DNS: Nachteile

Balancing

- Nur statische Lastverteilung ist möglich
- Die Reihenfolge der IPs wird vom DNS ein Mal bestimmt, aber danach gecached
 - ▶ Verteilung kann zufällig ungleich werden, da Balancing nur unregelmäßig erfolgt
 - ▶ Neue Server erst nach gewisser Zeit gleich stark ausgelastet

Failover-Verhalten

- Vom Client kontrolliert, nicht vom Server oder DNS
 - ► Lange Wartezeiten bis zum Failover sind möglich



Fazit

Was wurde gemacht?

- Analyse und Implementierung von Resilienzstrategien
- Fallstudien und Praxisbeispiele
- Implementierungen in Python



Fazit

Fallstudie: Netflix

- Nutzung von Hystrix für Circuit-Breaker
- Dynamisches Load Balancing
- Skalierung und Fehlertoleranz



Diskussion

- Erweiterung der Strategien auf andere Szenarien
- Entwicklung neuer Muster zur Resilienzsteigerung
- Untersuchung ökonomischer Auswirkungen



Quellen I

- [1] Bhavya Alankar, Gaurav Sharma, Harleen Kaur, Raul Valverde, and Victor Chang. Experimental setup for investigating the efficient load balancing algorithms on virtual cloud. *Sensors*, 20(24), 2020.
- [2] ClouDNS. What is Round-Robin DNS? Optimize Server Load. https://www.cloudns.net/wiki/article/182/.
- [3] Microsoft. Retry pattern.
- [4] Tom Schöner, Kai von Luck, Tim Tiedemann, Ulrike Steffens, and Stefan Sarstedt. Analyse abstrakter architekturmodelle in verteilten systemen. 2017.



Cheatsheet zum Lernen

- TODO, damit hätten wir etwas, was noch keine Gruppe hat.
- die wichtigsten Definitionen usw hier in kleinerer Schrift (tiny)



Cheatsheet: Wichtige Definitionen und Konzepte

1. Grundbegriffe

Resilienz = Übergeordnetes Konzept, Fehlertoleranz + Aspekte wie Wiederherstellung, Anpassungsfähigkeit und präventive Maßnahmen

Fehlertoleranz = Fokus auf unmittelbarer Bewältigung von Fehlern während des Systembetriebs

Ziel: Störungen im laufenden Betrieb vermeiden

2. Resilienzstrategien

Redundanz: Vervielfältigung kritischer Komponenten oder Funktionen zur Erhöhung der Zuverlässigkeit und Verfügbarkeit.

-> aktive vs. passive Redundanz; Redundanzebenen!

Partionierung: Physische Unterteilung von Daten in kleinere, logisch zusammenhängende Einheiten für Skalierbarkeit, Leistung und Flexibilität. Skalierung: Flexible Anpassung von Ressourcen an veränderte Anforderungen.
-> vertikal vs. horizontal vs.

-> vertikal vs. horizontal vs. automatisch!

3. Fehlertoleranzstrategien + Pattern

Retry-Muster: Wiederholt fehlgeschlagene Operationen, oft mit Backoff-Strategien.

Circuit-Breaker: Isoliert fehlerhafte Dienste, unterbricht Anfragen bei wiederholtem Fehler, verhindert kaskadierende Ausfälle.

-> clientseitig vs. dienstseitig vs. proxy-basiert!

Load-Balancing: Verteilung der Last auf mehrere Server zur Verbesserung von Leistung und Ausfallsicherheit.

Load-Balancing-Strategien:

- Round Robin DNS: rotierende Rückgabe von IP-Adressen
- Least Connection: Aufgabe an Dienst mit den wenigsten aktiven Netzwerkverbindungen

